

So let's see what would happen if doing such a thing.

Softmax 和交叉熵的求导过程

Softmax

$$y_i = \frac{e^{a_i}}{\sum_k e^{a_k}}, \text{ where } k=1, \dots, K$$

Softmax 的性质 (代码当时使用)

由于 softmax 中使用了指数运算, 即 e^{a_i} 运算, 则在使用 softmax 时, 若 a_i 或 a_k 过大, 则在 numpy 中可能会出现 inf 的结果. inf 是我们不想看到的, 因为会丢失很多信息. 所以要想办法解决这个问题.

softmax 有一条重要性质, 即 $\text{softmax}(a_i) = \text{softmax}(a_i + c)$, 其中 c 为任意常数.

$$\begin{aligned} \frac{e^{a_i + c}}{\sum_k e^{a_k + c}} &= \frac{e^{a_i} \cdot e^c}{\sum_k (e^{a_k} \cdot e^c)} && \text{coding 时所以减去最大值以达到优化过程,} \\ &= \frac{e^{a_i} \cdot \cancel{e^c}}{\cancel{e^c} \cdot \sum_k e^{a_k}} && \text{即 } c = \max(a) \\ &= \frac{e^{a_i}}{\sum_k e^{a_k}} && \text{softmax}(a_i) = \text{softmax}(a_i - \max(a)) \end{aligned}$$

相等

Softmax 的求导过程

$$\frac{\partial y_i}{\partial a_j} = \frac{\partial}{\partial a_j} \left(\frac{e^{a_i}}{\sum_k e^{a_k}} \right) \rightarrow \begin{matrix} g(a_i) = g_i \\ h(a) = h \end{matrix}$$

求导公式

$$f' = \frac{g_i' \cdot h - g_i \cdot h'}{h^2}$$

此时会出现两种情况, 即当 $i=j$ 和当 $i \neq j$ 时.

① 当 $i=j$ 时:

$$\begin{aligned} \frac{\partial y_i}{\partial a_j} &= \frac{e^{a_i} \cdot \sum_k e^{a_k} - e^{a_i} \cdot e^{a_j}}{\left(\sum_k e^{a_k} \right)^2} \\ &= \frac{e^{a_i} \cdot \sum_k e^{a_k}}{\left(\sum_k e^{a_k} \right)^2} - \frac{e^{a_i} \cdot e^{a_j}}{\left(\sum_k e^{a_k} \right)^2} \\ &= y_i - y_i^2 \\ &= y_i (1 - y_i) \end{aligned}$$

$\frac{(e^{a_j})^2}{\left(\sum_k e^{a_k} \right)^2} = y_j^2$

② 当 $i \neq j$ 时

$$\frac{\partial y_i}{\partial a_j} = \frac{0 \cdot e^{a_j} - e^{a_i} \cdot e^{a_j}}{\left(\sum_k e^{a_k} \right)^2} = -y_i \cdot y_j$$

Cross Entropy (交叉熵) 的求导过程

什么是交叉熵?

$$\mathcal{L} = - \sum_i \text{label}_i \cdot \log(y_i)$$

其中, y_i 为 softmax 后预测的结果,

label 为真实结果 (ground truth),

log 的底数为 e , 为了方便求导.

对于 softmax 的输入 o_k 而言, (这里的 o_k 是为了进行区分)

$$\frac{\partial \mathcal{L}}{\partial o_k} = \frac{\partial \mathcal{L}}{\partial y_k} \cdot \frac{\partial y_k}{\partial o_k}$$

$$\frac{\partial \mathcal{L}}{\partial y_k} = \frac{\partial - \sum_k \text{label}_k \cdot \log(y_k)}{\partial y_k}$$

$$= - \sum_k \text{label}_k \cdot \frac{\partial \log(y_k)}{\partial y_k}$$

$$= - \sum_k \text{label}_k \cdot \frac{1}{y_k}$$

由前面得到的 softmax 求导结果可知

$$\frac{\partial \mathcal{L}}{\partial o_k} = - \text{label}_i (1 - y_i) - \sum_{k \neq i} \text{label}_k \cdot \frac{1}{y_k} (-y_k y_i)$$

$$= - \text{label}_i + \text{label}_i y_i + \sum_{k \neq i} \text{label}_k \cdot y_i$$

$$= - \text{label}_i + y_i \left(\text{label}_i + \sum_{k \neq i} \text{label}_k \right)$$

$$= - \text{label}_i + y_i \cdot \boxed{\sum_k \text{label}_k} \rightarrow \text{label 是一个 one-hot encoding}$$

如 $[0, 0, 1, 0]$, 所以求和结果为 1.

$$= y_i - \text{label}_i$$

最终结果是 cross-entropy + softmax 的求导结果.

Sigmoid 求导

$$\sigma(x) = \frac{1}{1 + e^{-x}} \rightarrow u(x) \rightarrow u$$

$$\sigma'(x) = \frac{\partial \sigma(x)}{\partial x} = \frac{\partial \sigma}{\partial u} \cdot \frac{\partial u}{\partial x}$$

$$= -\frac{1}{u^2} \cdot (-e^{-x})$$

$$= \frac{e^{-x}}{(1 + e^{-x})^2}$$

$$= \frac{1 + e^{-x} - 1}{(1 + e^{-x})^2} \rightarrow -\sigma^2(x)$$

$$= \sigma(x) - \sigma^2(x)$$

$$= \sigma(x) (1 - \sigma(x))$$

$$= \sigma(1 - \sigma)$$